

Случайни времеви редове

Стационарност (1/2)

$$E(Y_t) = \mu$$

$$D(Y_t) = E[(Y_t - \mu)^2] = \sigma^2$$

$$Cov(Y_t, Y_{t-k}) = E[(Y_t - \mu)(Y_{t-k} - \mu)] = \gamma_k$$

Стационарност (2/2)

$$\bar{Y} = \frac{1}{n} \sum_{t=1}^n Y_t$$

$$\hat{\sigma}^2 = \frac{1}{n-1} \sum_{t=1}^n (Y_t - \bar{Y})^2$$

$$\hat{\gamma}_k = \frac{1}{n-1} \sum_{t=1}^n (Y_t - \bar{Y})(Y_{t-k} - \bar{Y}) \quad k = 1, 2, \dots$$

Коефициент на Автокорелация

$$\rho_k = \text{Corr}(Y_t, Y_{t-k}) = \frac{\text{Cov}(Y_t, Y_{t-k})}{\sqrt{D(Y_t)D(Y_{t-k})}} = \frac{\gamma_k}{\sigma^2}$$

$$\rho_0 = 1$$

$$\rho_{-k} = \rho_k$$

Оценка на автокорреляционный коэффициент

$$\hat{\rho}_k = \frac{\hat{\gamma}_k}{\hat{\sigma}^2} = \frac{\sum_{t=k+1}^n (Y_t - \bar{Y})(Y_{t-k} - \bar{Y})}{\sum_{t=1}^n (Y_t - \bar{Y})^2} \quad k = 1, 2, \dots$$

$$E(\hat{\rho}_k) = \rho_k$$

$$D(\hat{\rho}_k) \cong \frac{1}{n}$$

Бял шум


$$Y_t = e_t$$

$$E(e_t) = 0, \quad D(e_t) = \sigma^2,$$

$$\text{Cov}(e_t, e_k) = 0 \quad \text{за всички} \quad t \neq k$$

$$\rho_0 = 1, \quad \rho_k = 0 \quad k = 1, 2, \dots$$

Бял шум



Тест на Ljung-Box


$$Q = n(n+2) \sum_{k=1}^L \frac{\hat{\rho}_k^2}{n-k}$$

$$Q \sim X^2$$


```
[H,pValue,Qstat,CriticalValue] = lbqtest(y,[20 30  
40 50]);
```

H	pValue	Qstat	CriticalValue
0	0.741	15.6024	31.4104
0	0.8534	22.0165	43.773
0	0.8848	29.6479	55.7585
0	0.8518	39.6861	67.5048

Автокорелационна функция на “бял шум”



Случайно блуждаене (Random walk)

(1/2)

$$Y_t = Y_{t-1} + e_t$$

$$E(e_t) = \mu, D(e_t) = \sigma^2, Cov(e_t, e_{t-k}) = 0 \text{ for } k \neq 0$$

$$Y_0 = 0, \quad t = 0$$

$$Y_1 = e_1, Y_2 = e_1 + e_2, \dots$$

Случайно блуждаене (Random walk)


(2/2)

$$Y_t = \sum_{i=0}^t e_i$$

$$E(Y_t) = E\left(\sum_{i=0}^t e_i\right) = t\mu$$

$$D(Y_t) = t\sigma^2$$

Случайно блуждаене



Тест на Dickey-Fuller

$$Y_t = \phi Y_{t-1} + e_t$$

$$\Delta Y_t = (\phi - 1)Y_{t-1} + e_t,$$

$$\Delta Y_t = \delta Y_{t-1} + e_t, \quad \delta = (\phi - 1)$$

$$H_0 : \delta = 0$$

```
[H,pValue,TestStat,CriticalValue] =  
adftest(x);
```

H	pValue	Qstat	Critical Value
0	0.936	-1.0419	-3.4145

Линейни модели на времеви редове - $ARIMA(R,d,M)$

Първа част

Безусловна и условна средна

- ▶ За случайната променлива y_t , безусловната средна стойност е математическото очакване $E(y_t)$.
- ▶ Условната средна на y очакваната стойност на y_t при зададено обуславящо множество Ω_t .
- ▶ Моделите на условната средна специфицират функционалната форма за $E(y_t | \Omega_t)$.

Статични модели на условната средна

- ▶ При статичните модели на условната средна условното множество от променливи се измерва едновременно със зависимата променлива y_t .
- ▶ Пример за статичен модел на условната средна е класическия линеен регресионен модел. При зададени x_t - вектор ред от екзогенни променливи в момента t , и β - вектор колона от коефициенти, условната средна на y_t се задава като линейна комбинация:

$$E(y_t|x_t) = x_t\beta$$

(т.е. обуславящото множество е $\Omega_t = x_t$).

Динамични модели на условната средна

- ▶ В теорията на времевите редове основно интересът е към динамичното поведение на една променлива във времето.
- ▶ Моделите на условната средна специфицират очакваната стойност на y_t като функция от историческа информация. Нека означим с H_{t-1} историята на процеса налична към момента t . Динамичните модели на условната средна специфицират еволюцията на условната средна във времето: $E(y_t | H_{t-1})$.
- ▶ Примери за историческа информация са:
 - ▶ Предишни наблюдения: y_1, y_2, \dots, y_{t-1}
 - ▶ Предишни иновации: e_1, e_2, \dots, e_{t-1} ,

Модели от тип “пълзящо средно” – МА(М)

$$Y_t = \mu + e_t + \theta_1 e_{t-1} + \theta_2 e_{t-2} + \dots + \theta_M e_{t-M}$$

$$E(Y_t) = \mu$$

$$D(Y_t) = E[(Y_t - \mu)^2] = E(e_t^2 + \theta_1^2 e_{t-1}^2 + \dots + \theta_M^2 e_{t-M}^2 + 2\theta_1 e_t e_{t-1} + \dots) \Rightarrow$$

$$D(Y_t) = \sigma_e^2 + \theta_1^2 \sigma_e^2 + \dots + \theta_M^2 \sigma_e^2 \Rightarrow$$

$$D(Y_t) = \sigma_e^2 (1 + \theta_1^2 + \dots + \theta_M^2)$$

MA(1) модел

$$Y_t = \mu + e_t + \theta_1 e_{t-1}$$

$$E(Y_t) = \mu, \quad D(Y_t) = \gamma_0 = \sigma_e^2(1 + \theta_1^2)$$

$$\gamma_1 = E[(Y_t - \mu)(Y_{t-1} - \mu)] = E[(e_t + \theta_1 e_{t-1})(e_{t-1} + \theta_1 e_{t-2})] \Rightarrow$$

$$\gamma_1 = \theta_1 \sigma_e^2$$

$$\gamma_k = E[(e_t + \theta_1 e_{t-1})(e_{t-k} + \theta_1 e_{t-k-1})] = 0 \quad \text{for } k > 1$$

$$\rho_k = \frac{\gamma_k}{\gamma_0} = \begin{cases} \frac{\theta_1}{1 + \theta_1^2} & k = 1 \\ 0 & k > 1 \end{cases}$$

Пример 1

$$Y_t = 2 + e_t + 0.8e_{t-1}$$

Пример 1

```
ma1=arima('ma',0.8,'c',2, 'var',1)
```

```
ma1 =
```

```
ARIMA(0,0,1) Model:
```

```
-----
```

```
Distribution: Name = 'Gaussian'
```

```
P: 0
```

```
D: 0
```

```
Q: 1
```

```
Constant: 2
```

```
AR: {}
```

```
SAR: {}
```


```
MA: {0.8} at Lags [1]
```

```
SMA: {}
```

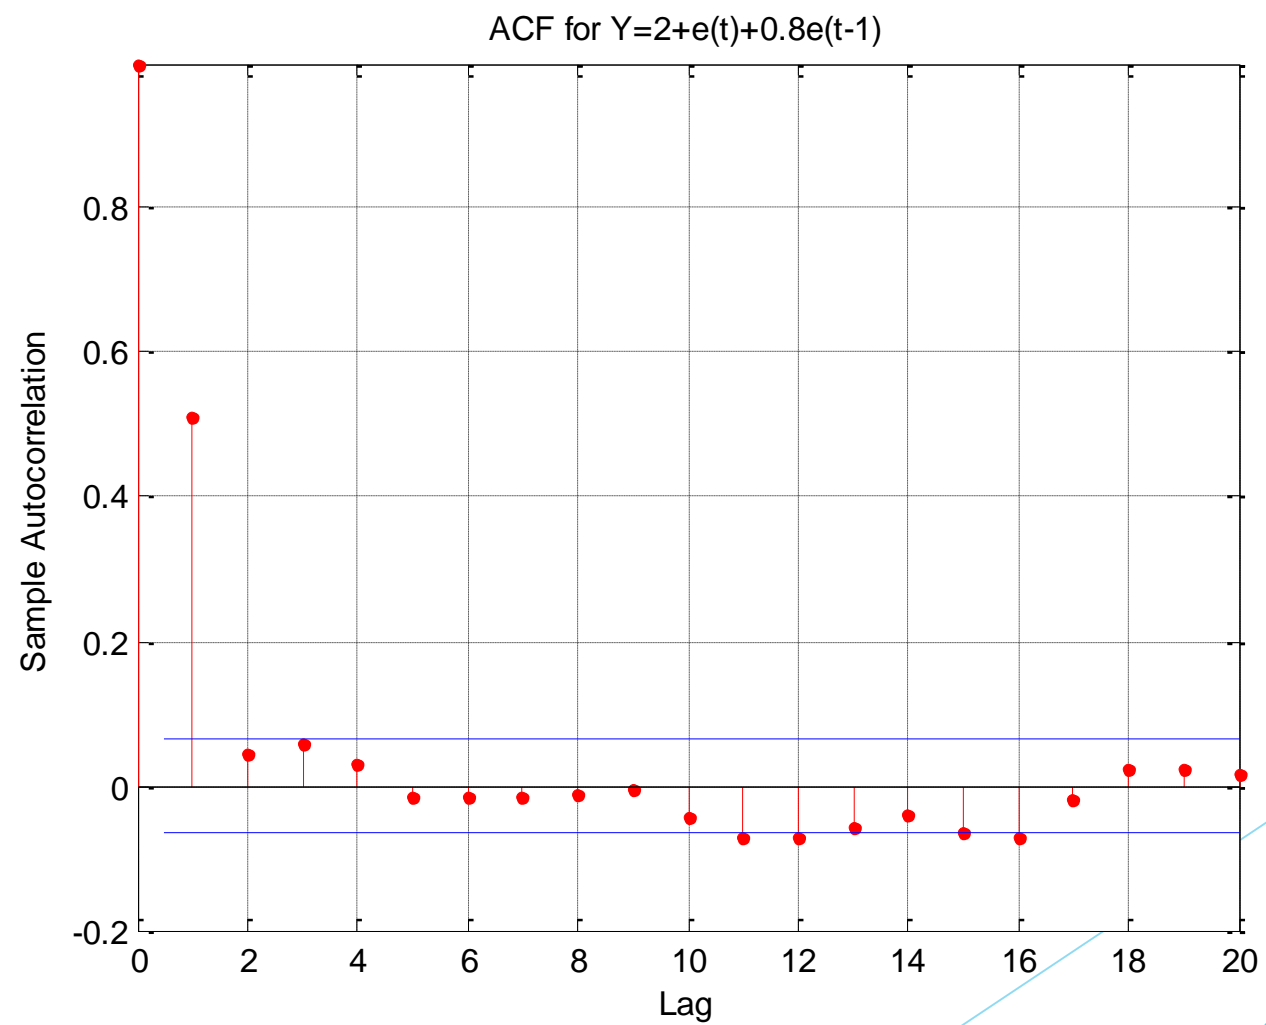
```
Variance: 1
```

```
y=simulate(ma1,1000);
```

Пример 1



Пример 1



MA(2) модел

$$Y_t = \mu + e_t + \theta_1 e_{t-1} + \theta_2 e_{t-2}$$

$$\gamma_1 = E[(e_t + \theta_1 e_{t-1} + \theta_2 e_{t-2})(e_{t-1} + \theta_1 e_{t-2} + \theta_2 e_{t-3})] \Rightarrow$$

$$\gamma_1 = \theta_1 \sigma_e^2 + \theta_2 \theta_1 \sigma_e^2 = \theta_1 (1 + \theta_2) \sigma_e^2$$

$$\gamma_2 = \theta_2 \sigma_e^2$$

$$\gamma_k = 0 \quad \text{при } k > 2$$

MA(2) модел

$$\rho_1 = \frac{\theta_1(1 + \theta_2)}{1 + \theta_1^2 + \theta_2^2}$$

$$\rho_2 = \frac{\theta_2}{1 + \theta_1^2 + \theta_2^2}$$

$$\rho_k = 0 \quad \text{при } k > 2$$

Пример 2

$$Y_t = 2 + e_t + 0.6e_{t-1} - 0.3e_{t-2}$$

Пример 2

```
ma2=arima('ma',[0.6 -0.3],'c',2, 'var',1)
```

```
ma1 =
```

ARIMA(0,0,2) Model:

Distribution: Name = 'Gaussian'

P: 0

D: 0

Q: 2

Constant: 2

AR: {}


SAR: {}

MA: {0.6 -0.3} at Lags [1 2]

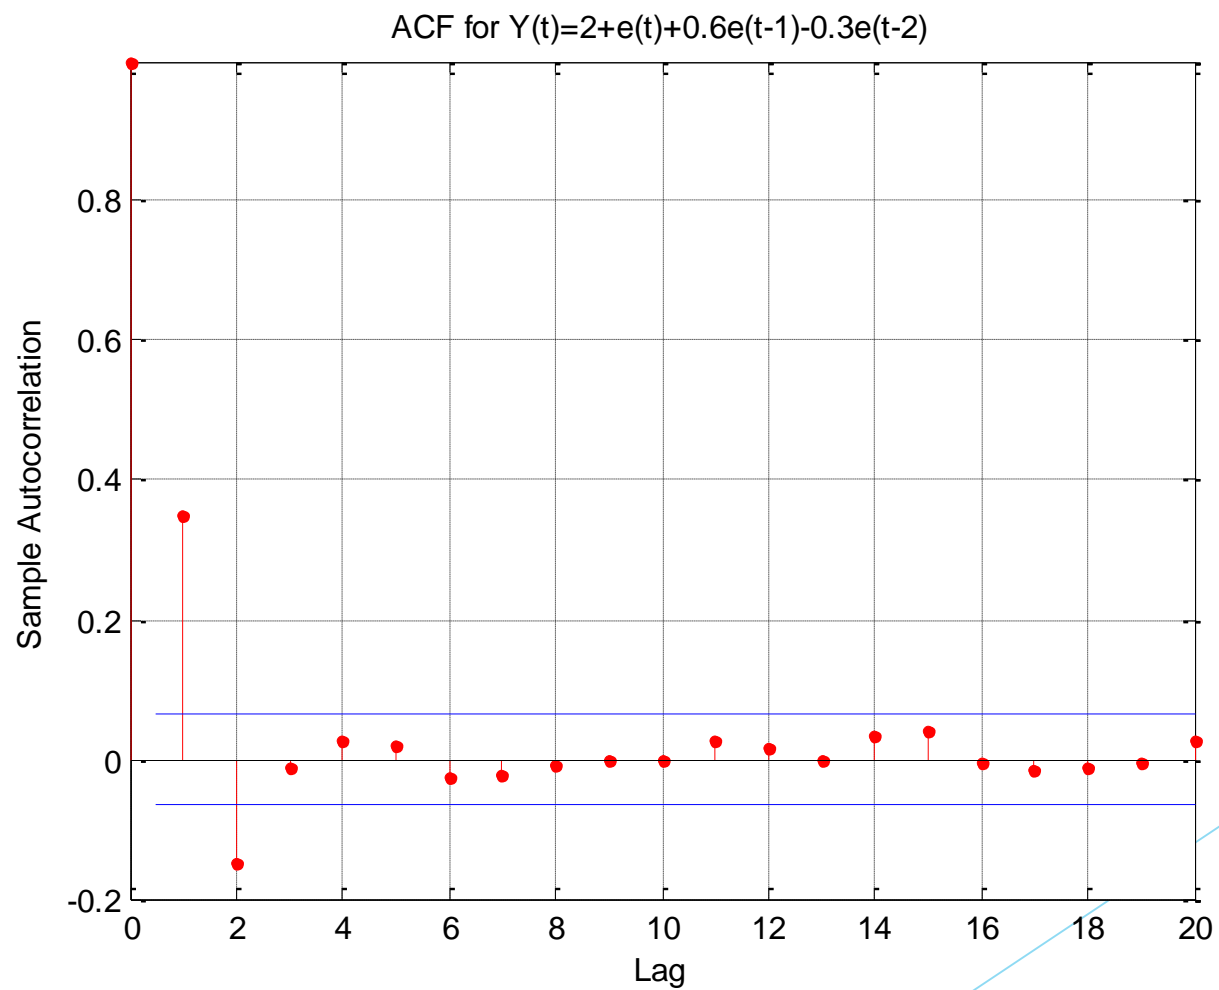
SMA: {}

Variance: 1

Пример 2



Пример 2



Автокорреляции при МА(М) модел

$$\rho_k = \begin{cases} \frac{\theta_k + \theta_1 \theta_{k+1} + \dots + \theta_{M-k} \theta_M}{1 + \theta_1^2 + \theta_2^2 + \dots + \theta_M^2} & k = 1, \dots, M \\ 0 & k > M \end{cases}$$

Авторегрессионни модели

$$Y_t = c + \varphi_1 Y_{t-1} + \varphi_2 Y_{t-2} + \cdots + \varphi_R Y_{t-R} + e_t$$

$$E(Y_t) = E(Y_{t-1}) = \cdots = E(Y_{t-R}) = \mu \Rightarrow$$

$$\mu = c + \varphi_1 \mu + \varphi_2 \mu + \cdots + \varphi_R \mu \Rightarrow$$

$$\mu = \frac{c}{1 - \varphi_1 - \varphi_2 - \cdots - \varphi_R}$$

AR(1) модел

$$Y_t = c + \phi_1 Y_{t-1} + e_t$$

$$\mu = \frac{c}{1 - \phi_1}$$

Нека $\mu = 0 \Rightarrow Y_t = \phi_1 Y_{t-1} + e$

$$\gamma_0 = E[(\phi_1 Y_{t-1} + e_t)^2] = E(\phi_1^2 Y_{t-1}^2 + e_t^2 + 2\phi_1 Y_{t-1} e_t) = \phi_1^2 \gamma_0 + \sigma_e^2 \Rightarrow$$

$$\gamma_0 = \frac{\sigma_e^2}{1 - \phi_1^2}$$

$$\gamma_1 = E[Y_{t-1}(\phi_1 Y_{t-1} + e_t)] = \phi_1 \gamma_0 = \phi_1 \frac{\sigma_e^2}{1 - \phi_1^2}$$

$$\gamma_2 = E[Y_{t-2}(\phi_1^2 Y_{t-2} + \phi_1 e_{t-1} + e_t)] = \phi_1^2 \gamma_0$$

AR(1) модел

$$\gamma_k = \phi_1^k \gamma_0 = \frac{\phi_1^k \sigma_e^2}{1 - \phi_1^2}$$

$$\rho_k = \frac{\gamma_k}{\gamma_0} = \phi_1^k$$

$$|\phi_1| < 1$$

Пример 3

$$Y_t = 0.9Y_{t-1} + 2 + e_t$$

Пример 3

```
ar1=arima('c',2, 'var',1,'ar',0.9)
```

```
ar1 =
```

```
ARIMA(1,0,0) Model:
```

```
-----
```

```
Distribution: Name = 'Gaussian'
```

```
    P: 1
```

```
    D: 0
```

```
    Q: 0
```

```
Constant: 2
```

```
    AR: {0.9} at Lags [1]
```

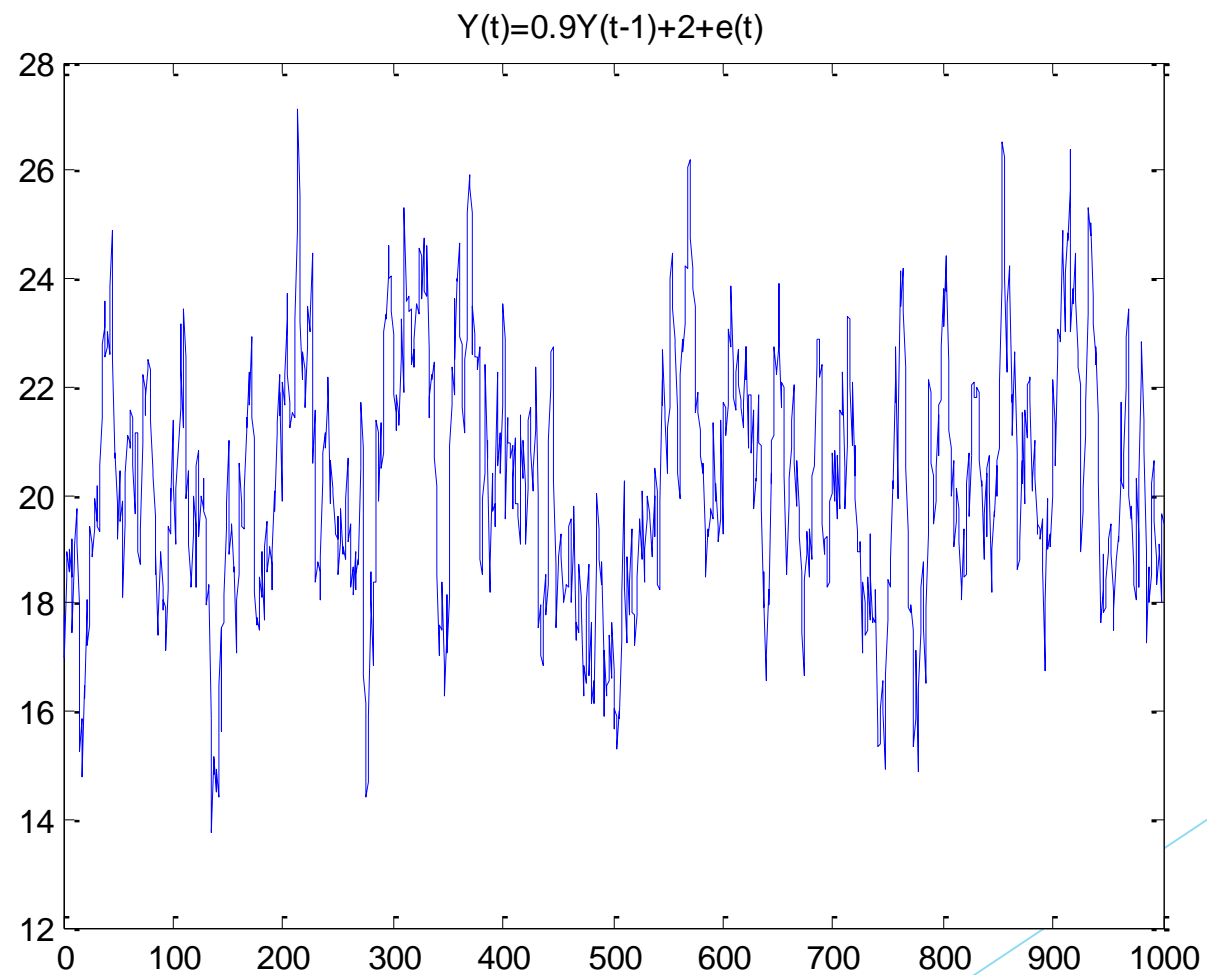
```
    SAR: {}
```

```
    MA: {}
```


```
    SMA: {}
```

```
Variance: 1
```

Пример 3




Пример 3




Пример 4

$$Y_t = -0.7Y_{t-1} + 2 + e_t$$


Пример 4



Пример 4




Пример 4



Пример 5

$$Y_t = 0.9Y_{t-1} - 0.7Y_{t-2} + 2 + e_t$$

Пример 5



Пример 5

